

DwaTalk

Assistant pharmacie conversationnel
en darija, arabe et français, à l'écrit et à la voix

Challenge #1 — Arabic/Darija Patient Pharmacy Assistance

Rapport technique : état de l'art, architecture et évaluation

Équipe

[Noms des membres de l'équipe]

Septembre 2026

Sommaire

1. Introduction et problématique.....	3
1.1 Contexte	3
1.2 Ce qui rend la darija difficile	3
1.3 Périmètre et principes	3
2. État de l’art	4
2.1 Modèles de langue pour l’arabe et ses dialectes	4
2.2 Ressources pour la darija.....	4
2.3 Grands modèles de langue et apprentissage few-shot.....	4
2.4 Reconnaissance de la parole	4
2.5 Positionnement de notre approche	5
3. Données.....	5
3.1 Référentiel des médicaments.....	5
3.2 Annuaire des pharmacies	5
3.3 Jeu de phrases annotées	6
4. Architecture et pipeline.....	6
4.1 Reconnaissance vocale	7
4.2 Compréhension du langage (NLU).....	7
4.3 Résolution des entités (entity linking).....	8
4.4 Gestion du dialogue et réponse	8
4.5 API.....	9
4.6 Interface	9
5. Évaluation	9
5.1 Protocole	9
5.2 Résultats	10
5.3 Analyse	10
5.4 Résolution des entités	11
5.5 Reconnaissance vocale.....	11
5.6 Scénarios de test automatisés.....	11
6. Limites et perspectives	11
6.1 Limites	11
6.2 Perspectives.....	12
7. Conclusion	12
Références.....	12

1. Introduction et problématique

1.1 Contexte

Au Maroc, les patients formulent leurs demandes à la pharmacie par des messages courts, informels et souvent oraux, en passant librement de la darija à l'arabe standard ou au français. Ils demandent si un médicament est disponible, combien il coûte, s'il est remboursé, ou quelle pharmacie est ouverte près de chez eux.

Le challenge demande de concevoir un service capable d'accepter ces demandes **à l'écrit ou à la voix**, d'en identifier l'**intention**, d'en extraire les informations utiles (nom du médicament, dosage, quantité, lieu...) et de renvoyer une **interprétation structurée** plutôt qu'une simple réponse libre, le tout exposé par une **API**. DwaTalk est notre réponse à ce cahier des charges.

1.2 Ce qui rend la darija difficile

La darija cumule plusieurs difficultés qu'un système de traitement du langage doit absorber :

- **Pas d'orthographe normalisée.** Un même mot s'écrit « chhal », « ch7al » ou « شحال » selon l'auteur.
- **Deux écritures.** L'alphabet arabe coexiste avec une graphie latine (« arabizi ») qui note par des chiffres les sons absents du français : le chiffre 3 note la lettre ع, le chiffre 7 la lettre ح et le chiffre 9 la lettre ق.
- **Alternance des langues dans une même phrase :** « wach kayn doliprane 1g? bghit juj boites » mêle darija, nom commercial français et dosage.
- **Noms de médicaments approximatifs**, mal orthographiés (« dolipran ») ou écrits en arabe (« دوليبران »).
- **Peu de données annotées**, et quasiment aucune dans le domaine pharmaceutique.

1.3 Périmètre et principes

DwaTalk **informe et oriente** : il donne le prix, la forme, le remboursement d'un médicament et propose des pharmacies à contacter. Il **ne remplace ni le pharmacien ni le médecin**. Trois principes ont guidé la conception :

- **Ne jamais inventer d'information médicale.** Nos bases sont des registres d'autorisation et de remboursement : elles ne contiennent ni posologie ni effets indésirables. Quand on les lui demande, DwaTalk le dit et renvoie vers la notice ou le pharmacien.
- **Préférer l'aveu d'ignorance à une réponse fausse.** Un médicament reconnu avec un faible niveau de confiance n'est jamais présenté comme une réponse.
- **Rester honnête sur le stock.** DwaTalk ne connaît pas l'état des rayons en temps réel. Il oriente vers des pharmacies à appeler pour confirmer.

2. État de l’art

2.1 Modèles de langue pour l’arabe et ses dialectes

Les modèles de type BERT [3], pré-entraînés sur de grands corpus puis affinés sur une tâche, ont été déclinés pour l’arabe. **AraBERT** [1] est entraîné principalement sur de l’arabe standard. **ARBERT** et **MARBERT** [2] élargissent la couverture aux dialectes : MARBERT est entraîné sur des tweets dialectaux et évalué sur ARLUE, un banc d’essai de 42 jeux de données.

Pour la darija spécifiquement, **DarijaBERT** [4] est le premier modèle BERT dédié au dialecte marocain. Il est entraîné sur environ 100 millions de mots (691 Mo) issus d’histoires, de commentaires YouTube et de tweets, et décliné en variantes pour la graphie latine (DarijaBERT-arabizi) et pour le mélange des deux écritures (DarijaBERT-mix). Ces encodeurs doivent toutefois être **affinés sur des données annotées** propres à la tâche visée, ce qui suppose d’en disposer en quantité suffisante.

2.2 Ressources pour la darija

Le corpus **MADAR** [5] rassemble des phrases parallèles dans les dialectes de 25 villes arabes, dont Fès et Rabat, ainsi qu’en arabe standard, en anglais et en français, dans le domaine du voyage. Le **Darija Open Dataset (DODa)** [6] est une ressource collaborative ouverte de traduction darija–anglais, écrite dans les deux alphabets et forte d’environ 100 000 entrées dans ses versions récentes.

Ces ressources sont généralistes (voyage, traduction, réseaux sociaux) : aucune ne porte sur les échanges entre patients et pharmacies. C’est ce qui nous a conduits à constituer un jeu annoté propre au projet (section 3.3).

2.3 Grands modèles de langue et apprentissage few-shot

Brown et al. [7] ont montré qu’un grand modèle de langue peut accomplir une tâche à partir de quelques exemples placés dans son invite, **sans réentraînement** (apprentissage « few-shot »). Cette approche convient bien aux situations où les données annotées sont rares, comme la nôtre.

Du côté de la darija, **Atlas-Chat** [8] propose les premiers grands modèles spécialisés (2, 9 et 27 milliards de paramètres), affinés sur environ 450 000 instructions, et introduit DarijaMMLU pour les évaluer. Nous utilisons pour notre part **gpt-oss-20b** [9], un modèle à poids ouverts de 20,9 milliards de paramètres (dont 3,6 milliards actifs par mot), accessible gratuitement via Ollama Cloud.

2.4 Reconnaissance de la parole

Whisper [10] est un modèle de reconnaissance de la parole entraîné sur 680 000 heures d’audio multilingue faiblement supervisé. Il se montre robuste sans affinage (« zero-shot ») sur de nombreuses langues. La darija ne fait cependant pas partie des langues qu’il distingue : il la transcrit en arabe ou en français approchant. L’affiner sur la darija est possible, mais demande un corpus audio transcrit dont nous ne disposons pas.

2.5 Positionnement de notre approche

Avec 99 phrases annotées, affiner un encodeur comme DarijaBERT aurait produit un modèle instable et difficile à évaluer honnêtement. Nous avons donc retenu :

- un **LLM en few-shot** pour la compréhension (intention et entités) ;
- une **résolution lexicale** des entités contre des référentiels officiels, qui garantit que tout médicament cité existe réellement ;
- **Whisper exécuté en local** pour la voix ;
- une **baseline classique** entraînée sur les mêmes données, pour mesurer ce que le LLM apporte réellement.

3. Données

3.1 Référentiel des médicaments

Trois sources publiques marocaines ont été collectées, nettoyées puis fusionnées :

Source	Contenu	Lignes
AMMPS (registre national, ammps.gov.ma)	DCI, classe thérapeutique, laboratoire, statut, prix	9 903
CNOPS (liste officielle 2014)	prix, taux de remboursement CNOPS	5 917
CNSS (médicaments admis au remboursement)	prix, base et taux de remboursement CNSS	8 978

Tableau 1 — Sources du référentiel des médicaments (lignes après nettoyage).

La fusion repose sur une clé normalisée **nom + dosage + forme**. 2 424 produits CNOPS ont trouvé leur correspondance dans l'AMMPS (41 %, écart attendu entre une liste de 2014 et un registre actuel). Côté CNSS, 3 376 des 6 591 produits distincts (51,2 %) étaient déjà connus : leur taux CNSS enrichit la ligne existante. Les 3 215 autres produits ont ajouté 4 533 lignes, une par conditionnement.

Le référentiel final compte **19 974 lignes**, dont **12 075 portent au moins un taux de remboursement**, contre 6 879 avant l'ajout de la CNSS. CNOPS et CNSS étant deux régimes distincts, leurs taux sont conservés séparément et jamais fusionnés.

Deux particularités sont documentées. La colonne CNSS intitulée « Princeps / Générique » contient des codes A, N, C et B qui, croisés avec les autres sources, **ne correspondent pas** au statut princeps ou générique : ils sont conservés tels quels sans être interprétés. Par ailleurs, la fusion AMMPS–CNOPS duplique les lignes des 219 clés présentes plusieurs fois des deux côtés, ce qui crée des variantes redondantes pour certains produits (voir section 6).

3.2 Annuaire des pharmacies

2 661 établissements ont été collectés depuis saydalia.ma, puis nettoyés et dédoublonnés en **2 652 fiches** : nom, téléphone, adresse, ville et, le cas échéant, horaires de garde. La source ne fournit pas de

coordonnées GPS fiables : seules les informations textuelles sont exploitées. Il ne s'agit pas d'un jeu de données ouvert, son usage est limité au prototype.

3.3 Jeu de phrases annotées

Nous avons rédigé **99 phrases** de patients, annotées avec une intention parmi 7 et des entités parmi 6 types (MÉDICAMENT, DOSAGE, FORME, QUANTITE, PHARMACIE, LOCALISATION). Des fautes d'orthographe y sont volontairement introduites sur les noms de médicaments. Les positions des entités sont calculées automatiquement, et le script de génération refuse toute valeur absente de la phrase.

Intention	Description	Phrases
disponibilite_medicament	Le médicament est-il disponible ?	32
info_pharmacie	Adresse, téléphone, horaires, pharmacie de garde	14
prix_remboursement	Prix et taux de remboursement	13
salutation	Politesse, sans demande métier	13
posologie_information	Comment ou quand prendre un médicament	10
autre	Hors périmètre (diagnostic, symptôme...)	9
commande_reservation	Réserver ou acheter un médicament	8

Tableau 2 — Les 7 intentions et leur répartition dans le jeu annoté.

Répartition par langue : darija en graphie latine 49, français 29, darija en graphie arabe 8, phrases mixtes 7, arabe standard 6. Entités : 61 médicaments, 23 dosages, 17 formes, 11 quantités, 5 lieux, 4 noms de pharmacie.

La frontière entre disponibilité et commande. Les premières annotations étiquetaient différemment des phrases de même structure : « bghit juj boites » passait tantôt pour une demande de disponibilité, tantôt pour une commande. Nous avons fixé une règle : une commande exige un **verbe explicite de réservation ou d'achat** (n7goz, réserver, commander, nchri, acheter). « bghit doliprane », même suivi d'une quantité, reste une demande de disponibilité. Appliquer la règle a corrigé 5 étiquettes. Elle est écrite dans le schéma, donc transmise au modèle, et vérifiée par les tests automatisés.

4. Architecture et pipeline

La figure 1 présente le pipeline. Une question écrite entre directement dans l'étape de compréhension ; une question orale est d'abord transcrite par Whisper, puis renvoyée à l'utilisateur pour relecture avant d'être envoyée.




Figure 1 — Pipeline de traitement de DwaTalk.

4.1 Reconnaissance vocale

Le navigateur enregistre la question (API MediaRecorder) et l'envoie à l'endpoint `/transcription`. L'API la transcrit avec **faster-whisper**, une réimplémentation de Whisper, en local sur processeur et avec des poids quantifiés en 8 bits : aucun service tiers ne reçoit la voix du patient. Trois réglages améliorent le résultat :

- un **filtre de détection de la voix** (Silero VAD), qui évite que les silences soient « transcrits » en mots inventés ;
- une **amorce de vocabulaire** contenant des noms de médicaments courants au Maroc, qui aide le modèle à les orthographier ;
- des **limites** de 60 secondes et 10 Mo par enregistrement.

Le texte obtenu revient dans le champ de saisie au lieu d'être envoyé directement : Whisper ne connaissant la darija qu'approximativement, l'utilisateur doit pouvoir le corriger. L'endpoint `/chat/audio` enchaîne néanmoins transcription et compréhension en un seul appel pour les clients qui le souhaitent.

4.2 Compréhension du langage (NLU)

L'invite envoyée au modèle est construite à partir du schéma des intentions et entités, et de **9 exemples** du jeu annoté qui couvrent les 7 intentions et les différentes graphies. Elle impose des règles explicites : les valeurs d'entités doivent être recopiées telles quelles depuis le message, rien ne doit être inventé, et les mots « sidalia », « صيدلية » ou « pharmacie » sont des noms communs, jamais des noms de pharmacie. Sans cette dernière règle, le modèle annotait le mot lui-même, ce qui causait 5 des 11 écarts d'entités de la première évaluation.

Le modèle est appelé à température 0. Sa réponse JSON est **validée** : l'intention doit exister, les types d'entités aussi, et chaque valeur doit figurer dans le message d'origine. Les erreurs passagères du service (surcharge, limite de débit) sont retentées jusqu'à trois fois. Exemple de sortie :

```
Message : wach kayn doliprane 1g? bghit juj boites
{
  "intent": "disponibilite_medicament",
  "entities": [
    {"type": "MEDICAMENT", "value": "doliprane"},
    {"type": "DOSAGE", "value": "1g"},
    {"type": "QUANTITE", "value": "juj"},
    {"type": "FORME", "value": "boites"}
  ]
}
```

4.3 Résolution des entités (entity linking)

Le nom extrait par le modèle, souvent approximatif, est rapproché du référentiel en plusieurs étapes :

- **normalisation** (casse, accents, ponctuation) et **translittération** des noms écrits en arabe (« دوليبران » → DOLIPRANE) ;
- **comparaison approchée** (bibliothèque RapidFuzz) avec les noms commerciaux et avec les molécules (DCI). Une requête « ibuprofène » retrouve ainsi des produits dont le nom n'a aucun rapport, comme ADFENE ;
- filtrage éventuel par **dosage** ;
- attribution d'un **palier de confiance** : auto (score ≥ 90), a_confirmer (70 à 89), non_fiable (< 70).

Un **garde-fou** complète ces paliers. Le score de comparaison utilisé pour le classement favorise les noms courts contenus dans une requête longue : « Bidon Inexistante Xyz123 » obtenait 77 face au médicament OXISTAT, donc a_confirmer. Nous vérifions en plus la meilleure ressemblance mot à mot ; en dessous de 75, le candidat est déclassé en non_fiable. Ce contrôle porte sur la chaîne qui a réellement produit la correspondance (le nom commercial ou la molécule), faute de quoi les résolutions légitimes par molécule seraient rejetées.

Pour les pharmacies, le préfixe « Pharmacie » est ignoré, et le lieu filtre la recherche : d'abord par ville, puis par quartier dans l'adresse. Quand un quartier existe dans plusieurs villes (« Maarif » à Casablanca et à Sidi Bennour), la ville la plus représentée est retenue et **le choix est signalé** à l'utilisateur.

4.4 Gestion du dialogue et réponse

- **Multi-tours** : une demande de disponibilité sans lieu déclenche la question « Dans quelle ville ou quel quartier es-tu ? ». La réponse suivante, rattachée à la même session, est interprétée comme ce lieu.
- **Paliers de confiance appliqués** : un candidat non_fiable n'est jamais montré, et la réponse devient « Je ne trouve pas ... ». Un candidat a_confirmer est présenté comme une hypothèse à vérifier.
- **Question hors périmètre avec médicament reconnu** (« chno kaydir doliprane ? ») : la fiche est donnée avec une réserve plutôt qu'un « je n'ai pas compris ».
- **Remboursement** : le régime est toujours nommé (CNOPS, CNSS, ou les deux) ; un taux de 0 s'affiche « non remboursé ».

4.5 API

Méthode	Chemin	Rôle
POST	/chat	Question écrite → interprétation structurée et réponse
POST	/transcription	Enregistrement → texte (Whisper)
POST	/chat/audio	Enregistrement → transcription → même traitement que /chat
GET	/medicaments	Recherche de médicaments par nom ou molécule
GET	/pharmacies	Recherche de pharmacies par lieu et/ou nom
GET	/schema	Taxonomie des intentions et entités
GET	/health	Disponibilité du service

Tableau 3 — Endpoints de l'API (FastAPI). Documentation interactive sur /docs.

4.6 Interface

L'interface web (React) présente un accueil qui explique le service en darija, un assistant conversationnel, une page de recherche de médicaments, une page de recherche de pharmacies avec plan, et un historique des conversations conservé dans le navigateur. Les réponses sur un médicament sont affichées sous forme de **fiches structurées** (prix indicatif, forme, remboursement) accompagnées d'un rappel de sécurité. Sur téléphone, la barre latérale laisse place à une navigation en bas d'écran.

5. Évaluation

5.1 Protocole

Le jeu de test comprend les **90 phrases** du jeu annoté qui ne servent pas d'exemples au modèle. Deux approches y sont comparées :

- **LLM few-shot** : gpt-oss-20b via Ollama Cloud, à température 0, avec l'invite décrite en section 4.2.
- **Baseline classique** : pour l'intention, une régression logistique sur des n-grammes de caractères (2 à 5) pondérés TF-IDF, dont les réglages ont été fixés à l'avance et non ajustés sur les résultats. Elle est évaluée par validation croisée stratifiée à 5 plis : chaque phrase est prédite par un modèle qui ne l'a jamais vue, et les 9 exemples du LLM sont ajoutés à chaque entraînement pour que les deux approches disposent de la même information. Pour les entités, des règles et des lexiques rédigés à partir de connaissances générales, **jamais à partir des annotations du jeu de test**.

Mesures : exactitude et F1 macro pour l'intention ; précision, rappel et F1 pour les entités, une entité étant correcte si son type et sa valeur coïncident exactement (sans tenir compte de la casse).

5.2 Résultats

Mesure	LLM few-shot	Baseline
Intention — exactitude	97,8 %	67,8 %
Intention — F1 macro	97,3 %	61,5 %
Entités — précision	99,1 %	98,1 %
Entités — rappel	98,2 %	92,8 %
Entités — F1	98,6 %	95,4 %
Temps par phrase	plusieurs secondes, réseau	0,5 ms, hors ligne

Tableau 4 — LLM few-shot contre baseline classique, sur les mêmes 90 phrases.

Type d'entité	LLM	Baseline
MEDICAMENT	99,1 %	96,4 %
DOSAGE	100 %	92,3 %
FORME	93,3 %	96,8 %
QUANTITE	100 %	94,7 %
LOCALISATION	100 %	88,9 %
PHARMACIE	100 %	100 %

Tableau 5 — F1 par type d'entité.

Langue	Phrases	LLM	Baseline
Darija, graphie latine	44	42 / 44	33 / 44
Français	28	28 / 28	16 / 28
Darija, graphie arabe	8	8 / 8	5 / 8
Mixte	6	6 / 6	5 / 6
Arabe standard	4	4 / 4	2 / 4

Tableau 6 — Intentions correctement reconnues, par langue.

5.3 Analyse

L'intention est le point fort du LLM. Avec 81 phrases d'entraînement par pli (72 du jeu de test et les 9 exemples) pour 7 intentions et 5 variantes de langue, la baseline manque d'exemples pour généraliser ; le LLM, qui s'appuie sur sa connaissance préalable des langues, n'en a pas besoin.

Pour les entités, les deux approches sont proches. Les règles font même mieux que le LLM sur la forme galénique, pour un coût négligeable et sans connexion. Cela ouvre la voie à une architecture hybride : le LLM pour l'intention, les règles pour les entités ou en secours lorsque le service du LLM est indisponible.

Les deux erreurs d'intention du LLM sont instructives. « bghit njib juj boites » est prédite comme une commande : c'est précisément le cas limite de la règle de la section 3.3. « hal amoxicilline mashmoula bi at-ta'min ? », de l'arabe standard translittéré en caractères latins, est classée hors périmètre.

Évolution depuis la première mesure. La première évaluation donnait 94,5 % pour l'intention et 91,9 % de F1 sur les entités. Entre les deux mesures, trois éléments ont changé à la fois : la règle « sidalia » dans

l'invite, la correction de 5 étiquettes, et le remplacement d'un exemple (le jeu de test diffère donc d'une phrase). Le progrès est réel, mais il ne s'agit pas d'une mesure fine : sur 90 phrases, chaque exemple pèse 1,1 point.

5.4 Résolution des entités

Évaluée hors ligne sur des cas choisis à la main : **22 médicaments sur 22** sont correctement résolus en première position, fautes de frappe et graphie arabe comprises. Pour les pharmacies, **9 cas sur 10** : le seul échec, « Pharmacie Granada » sans lieu, n'a pas de bonne réponse, puisque trois pharmacies portent ce nom dans trois villes. Une requête absurde n'obtient jamais le palier auto.

5.5 Reconnaissance vocale

La chaîne vocale a été **validée fonctionnellement**, mais pas évaluée statistiquement. Une phrase française enregistrée par synthèse vocale (« Bonjour, est-ce que vous avez du Doliprane un gramme ? ») est transcrite mot pour mot, la langue est détectée à 98,5 %, et le traitement prend 2,8 secondes pour 3,9 secondes d'audio une fois le modèle chargé. Mesurer le taux d'erreur sur la darija demanderait un corpus de questions réellement prononcées, que nous n'avons pas constitué.

5.6 Scénarios de test automatisés

172 tests automatisés (pytest) vérifient le comportement du système. 170 s'exécutent en 3 secondes sans réseau, en remplaçant le LLM par une réponse fixée ; 2 chargent réellement Whisper. Ils vérifient notre code, pas la qualité du modèle, mesurée séparément. Les scénarios couvrent :

- les **parcours de conversation** : prix, disponibilité avec et sans lieu, dialogue en deux tours, question hors périmètre, posologie refusée, salutation, LLM indisponible ;
- les **cas de sécurité**, dont le test de non-régression « qwerty », qui obtenait auparavant une réponse chiffrée sur un vrai médicament à partir d'une correspondance non fiable ;
- la **résolution des entités** : fautes, graphie arabe, recherche par molécule, lieux ambigus, requêtes absurdes ;
- la **cohérence du jeu annoté** : chaque phrase est conforme au schéma, et la règle disponibilité / commande est respectée ;
- la **voix** (fichier vide, trop lourd, illisible, transcription réelle) et l'**API** (format JSON strict, CORS, codes d'erreur).

6. Limites et perspectives

6.1 Limites

- **Données de test rédigées par l'équipe.** Les 99 phrases ne sont pas des messages réels de patients, et certains sous-groupes sont très petits (4 phrases en arabe standard). C'est la principale limite de l'évaluation.
- **Darija à la voix** : Whisper n'a pas de modèle dédié ; la transcription reste approximative, d'où la relecture par l'utilisateur.

- **Dépendance à un service externe** pour le LLM, avec des surcharges ponctuelles sur l’offre gratuite.
- **Pas de stock en temps réel, pas d’information clinique**, et pas de position GPS des pharmacies.
- **Données** : la fusion AMMPS–CNOPS duplique certaines lignes, et la liste CNOPS date de 2014.
- **Prototype** : pas d’authentification, et l’état des conversations est gardé en mémoire.

6.2 Perspectives

- Collecter des **messages et enregistrements réels**, anonymisés, pour évaluer et enrichir le système.
- Mettre en place l’**architecture hybride** suggérée par l’évaluation.
- Envisager l’**affinage de DarijaBERT** [4], ou d’un modèle comme Atlas-Chat [8], à partir de quelques centaines de phrases annotées, et celui de **Whisper** sur de la darija parlée.
- Brancher une **source de stock** auprès de pharmacies partenaires pour répondre réellement à la question de disponibilité.

7. Conclusion

DwaTalk répond aux attentes du challenge : il accepte des demandes écrites et orales en darija, en arabe et en français, en extrait l’intention et les informations utiles avec une exactitude de 97,8 % et un F1 de 98,6 % sur notre jeu de test, les rattache à des référentiels officiels marocains, et expose l’ensemble par une API documentée et une interface web. Au-delà des chiffres, nous avons privilégié un comportement prudent : ne jamais inventer d’information médicale et préférer l’aveu d’ignorance à une réponse fausse, des exigences qui comptent davantage qu’un point d’exactitude dans une application de santé.

Références

- [1] W. Antoun, F. Baly, H. Hajj. AraBERT: Transformer-based Model for Arabic Language Understanding. 4th Workshop on Open-Source Arabic Corpora and Processing Tools (OSACT), 2020.
- [2] M. Abdul-Mageed, A. Elmadany, E. M. B. Nagoudi. ARBERT & MARBERT: Deep Bidirectional Transformers for Arabic. ACL-IJCNLP, 2021.
- [3] J. Devlin, M.-W. Chang, K. Lee, K. Toutanova. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. NAACL-HLT, 2019.
- [4] K. Gaanoun, A. M. Naira, A. Allak, I. Benelallam. DarijaBERT: a step forward in NLP for the written Moroccan dialect. International Journal of Data Science and Analytics, 20(2), 917–929, 2025 (publié en ligne en 2024). DOI : 10.1007/s41060-023-00498-2.
- [5] H. Bouamor, N. Habash, M. Salameh, W. Zaghouni, O. Rambow et al. The MADAR Arabic Dialect Corpus and Lexicon. LREC, 2018, p. 3387–3396.
- [6] A. Outchakoucht, H. Es-Samaali. Moroccan Dialect – Darija – Open Dataset. arXiv:2103.09687, 2021.
- [7] T. Brown et al. Language Models are Few-Shot Learners. NeurIPS, 2020.
- [8] G. Shang, H. Abdine, Y. Khoubrane, A. Mohamed et al. Atlas-Chat: Adapting Large Language Models for Low-Resource Moroccan Arabic Dialect. arXiv:2409.17912, 2024.
- [9] OpenAI. gpt-oss-120b & gpt-oss-20b Model Card. arXiv:2508.10925, 2025.

- [10] A. Radford, J. W. Kim, T. Xu, G. Brockman, C. McLeavey, I. Sutskever. Robust Speech Recognition via Large-Scale Weak Supervision. ICML, PMLR 202, 2023.